

Dekodowanie Wyobrażeń Ruchowych z sygnałów EEG o niskiej rozdzielczości przestrzennej: Analiza wykrywania anomalii przy użyciu metod nienadzorowanych uczenia maszynowego

Ignacy Berent
275255@student.pwr.edu.pl

Robert Rubaszek
maedje@typst.app

Abstract—

Index Terms— Unsupervised Machine Learning, Electroencephalography, Anomaly Detection, Brain-Computer Interface, Motor Imagery

I. WSTĘP

II. MATERIAŁY & METODY

A. Rejestracja danych

Dane wykorzystane w eksperymencie zostały zebrane za pomocą 14-kanalowego bezprzewodowego zestawu EEG *Emotiv Epoc X* [1]. Badanie przeprowadzono z udziałem jednego ochotnika, a cała procedura pomiarowa charakteryzowała się ścisłą sekwencyjnością czasową, w której poszczególne etapy następowały bezpośrednio po sobie:

- **Stan spoczynkowy (baseline):** 2,5 sekundy rejestracji sygnału w stanie relaksu (wytlumienie intencji kognitywnych),
- **Zadanie ruchowe (Motor Imagery):** 2,5 sekundy wyobrażenia ruchu (odpowiednio lewą lub prawą ręką),
- **Stan spoczynkowy (post-baseline):** 2,5 sekundy ponownej rejestracji sygnału w stanie spoczynku.

Łącznie zrealizowano cztery sesje pomiarowe (dwie dla lewej oraz dwie dla prawej ręki) o czasie trwania około 7,5 sekundy każda. Dodatkowo zarejestrowano 10-sekundowy sygnał szumu aparaturowego urządzenia. Surowe zapisy w formacie *.edf* zostały wyeksportowane do plików tekstowych *.csv* przy użyciu dedykowanego oprogramowania firmy Emotiv.

B. Metody analizy danych

Przetwarzanie sygnału EEG zrealizowano w nienadzorowanej architekturze potokowej typu End-to-End (E2E), integrującej cyfrową filtrację, ekstrakcję cech widmowych, redukcję wymiarowości oraz probabilistyczne modelowanie stanów mózgowych. Ciągły zapis EEG z 13 sprawnych kanałów fizycznych poddano segmentacji za pomocą techniki okna przesuwającego. Długość pojedynczego okna (epoki) ustalono na 0.5 sekundy, z krokiem przesunięcia wynoszącym 0.1 sekundy, co zapewniło 80-procentowe nakładanie się sąsiadujących segmentów sygnału.

W celu ekstrakcji cech zaimplementowano dwa niezależne podejścia, szeroko opisywane w literaturze dotyczącej interfejsów mózg-komputer [2]:

- 1) **Bezpośrednia analiza widmowa (Direct PSD)** – gęstość widmowa mocy estymowana klasyczną metodą Welch [3] bezpośrednio z fizycznych kanałów EEG.
- 2) **Dekompozycja na źródła niezależne (ICA)** – transformacja sygnału za pomocą algorytmu Infomax do przestrzeni wirtualnych komponentów niezależnych [4] przed analizą widmową.

Z wyznaczonych widm częstotliwościowych wyodrębniono średnią moc w pasmach sensorimotorycznych kluczowych dla paradygmatu wyobrażeń ruchowych (*Motor Imagery*): Mu (8-12 Hz) oraz Beta (13-30 Hz) [5]. Uzyskane wektory cech poddano standaryzacji statystycznej, a następnie redukcji wymiarowości za pomocą Analizy Składowych Głównych (PCA) w celu uniknięcia zjawiska klęski wymiarowości.

a) *Model Mieszanin Gaussowskich (GMM)*: Do globalnej, statycznej identyfikacji stanów wewnętrznych bez uwzględnienia zależności czasowej wykorzystano Model Mieszanin Gaussowskich (*Gaussian Mixture Model*) [6]. GMM jest nienadzorowanym algorytmem klastrowania probabilistycznego, traktującym gęstość rozkładu cech jako sumę ważoną skończonej liczby składowych gaussowskich.

W tym podejściu wyekstrahowane cechy ze wszystkich zarejestrowanych sesji pomiarowych (zarówno dla wyobrażenia ruchu lewej, jak i prawej ręki) zostały połączone w jedną globalną macierz. Przestrzeń cech zredukowano przy użyciu PCA do 3 składowych głównych. Model skonfigurowano dla dwóch komponentów ($n_{clusters} = 2$) odpowiadających stanom "rest" oraz "task", aplikując pełną macierz kowariancji (*covariance_type="full"*). Pozwoliło to na swobodne modelowanie geometrii elipsoid skupień w przestrzeni skompresowanej.

b) *Ukryty Model Markowa (HMM)*: Z uwagi na fakt, że procedura pomiarowa narzucała ścisłą sekwencyjność zdarzeń w czasie (odpoczynek -> zadanie -> odpoczynek), do jawnego modelowania dynamiki przejść czasowych zaimplementowano Ukryty Model Markowa (*Hidden Markov Model*) z emisjami gaussowskimi [7].

W przeciwieństwie do potoku GMM, model HMM trenowany był indywidualnie na pojedynczych plikach pomiarowych (z racji konieczności zachowania ciągłości chronologicznej próbek). Z powodu krytycznie małej liczby obserwacji w pojedynczym pliku (70 okien czasowych), przestrzeń wejściową zredukowano za pomocą PCA do restrykcyjnego poziomu 1 lub 2 składowych głównych. Zapobiegło to numerycznej niestabilności oraz błędom osłabliwości podczas estymacji macierzy kowariancji stanów ukrytych, reprezentujących dynamikę przejścia ochotnika między procesami kognitywnymi.

REFERENCES

- [1] Emotiv, “EPOC X: 14-Channel Wireless EEG Headset for Brain-Computer Interface (BCI) and Research.”
- [2] F. Lotte *et al.*, “A review of classification algorithms for EEG-based brain-computer interfaces: a 10-year update,” *Journal of Neural Engineering*, vol. 15, no. 3, p. 31005, 2018.
- [3] P. Welch, “The use of fast Fourier transform for the estimation of power spectra: A method based on time averaging over short, modified periodograms,” *IEEE Transactions on Audio and Electroacoustics*, vol. 15, no. 2, pp. 70–73, 1967.
- [4] S. Makeig, A. J. Bell, T.-P. Jung, and T. J. Sejnowski, “Independent component analysis of electroencephalographic data,” *Advances in Neural Information Processing Systems (NIPS 1995)*, vol. 8, pp. 145–151, 1996.
- [5] G. Pfurtscheller and F. H. L. da Silva, “Event-related EEG/MEG synchronization and desynchronization: basic principles,” *Clinical Neurophysiology*, vol. 112, no. 9, pp. 1402–1416, 2001.
- [6] D. A. Reynolds, “Gaussian Mixture Models,” *Encyclopedia of Biometrics*, vol. 741, pp. 741–747, 2009.
- [7] L. R. Rabiner, “A tutorial on hidden Markov models and selected applications in speech recognition,” *Proceedings of the IEEE*, vol. 77, no. 2, pp. 257–286, 1989.